Modelación Dinámica de la Tasa de Intervención en Colombia

Un enfoque ARIMA-X con efectos del Índice de Producción Industrial y análisis de intervención (2014–2026)

Walys Vera Herrera
Iván Andrés Durango Cogollo
Nicolás Buenaventura Schlesinger

Seminario de Series de Tiempo – Grupo 3
Instituto de Matemáticas, Facultad de Ciencias Exactas y Naturales
Universidad de Antioquia

Noviembre de 2026

Contenido

1. Introducción
2. Marco teórico
3. Metodología
4. Aplicación
5. Conclusiones

Motivación

Tasa de Intervención (y_t)

Principal herramienta del Banco de la República para controlar la inflación y estabilizar el ciclo económico.

IPI (x_t)

Índice de Producción Industrial (DANE): termómetro directo de la actividad económica real.

Pregunta: ¿los cambios en la producción industrial ayudan a explicar y pronosticar la tasa de intervención?

Problema con MCO

Las series macroeconómicas tienen **inercia** (memoria): la tasa de hoy depende de la de ayer.

- Errores autocorrelacionados.
- Varianza subestimada.
- Falsos positivos (regresión espuria).

Objetivos

Objetivo general

Modelar y pronosticar la dinámica de la Tasa de Intervención del Banco de la República en función del IPI, mediante regresión dinámica con errores ARIMA (ARIMA-X).

Objetivos específicos

1. Diagnosticar el orden de integración de las series (pruebas de raíz unitaria).
2. Identificar rezagos del IPI con pre-blanqueamiento y correlación cruzada (CCF).
3. Aislar el choque de la pandemia con análisis de intervención (dummy COVID-19).
4. Estimar por Máxima Verosimilitud y validar los residuos (ruido blanco y normalidad).
5. Evaluar el pronóstico fuera de muestra (RMSE, MAE, MAPE).

Modelos ARMA y ARIMA

ARMA(p, q) (Wei, 2006, p. 57)

$$\Phi(B)\, Y_t = \Theta(B)\, w_t, \qquad w_t \sim RB(0, \sigma^2)$$

- **Estacionario:** raíces de $\Phi(B) = 0$ fuera del círculo unitario.
- **Invertible:** raíces de $\Theta(B) = 0$ fuera del círculo unitario.

ARIMA(p, d, q) (Wei, 2006, pp. 69–71)

Una serie **no estacionaria homogénea** se vuelve estacionaria al diferenciarla d veces:

$$\phi(B)\,(1 - B)^d\, Y_t = \theta(B)\, \varepsilon_t$$

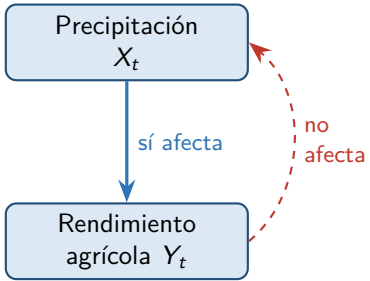
d = número de raíces unitarias del polinomio autorregresivo.

Variable exógena

- *Exo* = "fuera": X_t se determina **fuera** del proceso que genera Y_t.
- X_t puede afectar a Y_t, pero Y_t **no** afecta a X_t.
- Puede ser una variable explicativa, una dummy o una variable de intervención (Amézquita Bravo, 2021).

Ejemplo

La lluvia (X_t) afecta el rendimiento agrícola (Y_t), pero la cosecha no cambia la lluvia.



Estructura del modelo ARIMA-X

Con k variables exógenas $X_{1,t}, \ldots, X_{k,t}$ (Ortiz Martín, 2022, p. 20)

$$Y_t = \sum_{i=1}^{k} \beta_i X_{i,t} + \tilde{Y}_t \qquad \Longrightarrow \qquad \tilde{Y}_t = Y_t - \sum_{i=1}^{k} \beta_i X_{i,t}$$

- β_i: efecto directo de la variable exógena $X_{i,t}$.
- $\tilde{Y}_t$: **serie teórica**, libre del efecto de las exógenas.

Regresión con errores ARIMA

Se aplica la metodología ARIMA clásica a la serie teórica:

$$\Phi(B)\,(1-B)^d \Big(Y_t - \sum_{i=1}^{k} \beta_i X_{i,t} \Big) = \Theta(B)\, w_t, \qquad w_t \sim RB(0, \sigma^2)$$

Ejemplo: demanda de transporte aéreo en Colombia

Amézquita Bravo (2021), tesis de Maestría en Ciencias Económicas (UNAL).

Variable respuesta

Y_t: pasajeros mensuales del transporte aéreo.

Variable exógena

$X_{1,t}$: Producto Interno Bruto (PIB).

Modelo ARIMA-X

$$Y_t = \beta_1 \,\mathrm{PIB}_t + \tilde{Y}_t \quad \Longrightarrow \quad \Phi(B)(1-B)^d (Y_t - \beta_1 \,\mathrm{PIB}_t) = \Theta(B)\, w_t$$

Resultado

Incluir el PIB mejoró la precisión: MAPE y RMSE por debajo del 3 %. El precio del petróleo y otros choques resultaron no significativos.

Análisis de intervención y valores atípicos

Intervención — Box y Tiao (1975)

$$y_t = \frac{\omega(B)}{\delta(B)}\,\xi_t + N_t$$

- Pulso: $P_t = \mathbb{1}_{\{t=T\}}$
- Escalón: $S_t = \mathbb{1}_{\{t\geq T\}}$

Caso simple: $y_t = \omega S_t + N_t$.
$H_0:\ \omega = 0 \quad \text{vs} \quad H_1:\ \omega \neq 0.$

Atípicos — Chen y Liu (1993)

Intervenciones de fecha y tipo desconocidos:

- **AO** (aditivo): $x_t = \mathbb{1}_{\{t=T_0\}}$
- **TC** (transitorio): $x_t = \delta^{t-T_0}\mathbb{1}_{\{t\geq T_0\}}$, $\delta \approx 0.7$
- **LS** (cambio de nivel): $x_t = \mathbb{1}_{\{t\geq T_0\}}$
- **IO** (innovacional)

Etapas de la metodología



Todo el procesamiento se realizó en **R** (`forecast`, `tseries`, `lmtest`).

Datos

Muestra: mensual, enero 2014 – agosto 2026 ($T = 152$).

y_t: Tasa de Intervención

- Fuente: Banco de la República (diaria).
- Días no hábiles imputados con LOCF.
- Promedio aritmético mensual.

x_t: IPI (DANE)

- Logaritmo y desestacionalización STL.
- Escala $x_t = 100 \times \ln(\mathrm{IPI}^{SA})$.
- $\Delta x_t = 1 \approx 1\,\%$ de cambio en el IPI.

Dummy de pandemia

$$D_t^{COVID} = \begin{cases} 1, & \text{marzo 2020} \leq t \leq \text{octubre 2020} \\ 0, & \text{en otro caso} \end{cases}$$

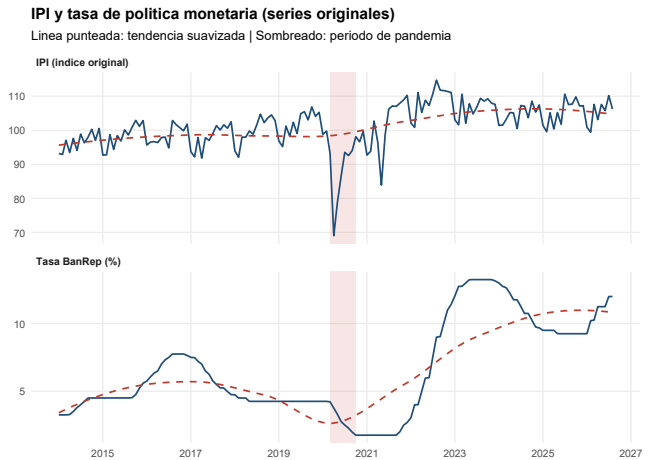
Modelos competitivos

Entrenamiento: 140 meses (ene 2014 – ago 2025) **Validación:** $h = 12$ meses (sep 2025 – ago 2026)

Modelo 0	Modelo 1	Modelo 2
ARIMA$(p, 1, q)$ univariado (benchmark)	ARIMA-X con IPI_t + COVID	ARIMA-X con IPI_t, IPI_{t-3}, IPI_{t-6} + COVID

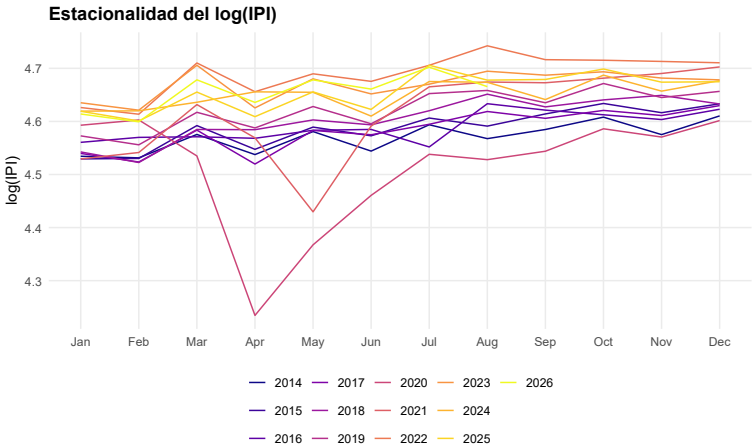
- Órdenes p y q elegidos minimizando AIC y BIC.
- Ljung-Box con 24 rezagos y $df = 24 - p - q$; normalidad con Shapiro-Wilk.
- Pronóstico evaluado con RMSE, MAE y MAPE.

Análisis exploratorio



- Ambas series son **no estacionarias** en media.
- 2020: caída sin precedentes del IPI ($-30.8\,\%$ entre febrero y abril).
- Respuesta: política monetaria expansiva (la tasa baja hasta $1.75\,\%$).

Estacionalidad del IPI



- Patrón anual repetitivo (caídas en abril por Semana Santa, y en enero).
- La tasa **no** es estacional.
- Por eso se desestacionaliza el log(IPI) con STL antes de usarlo como regresora.

Estacionariedad

Serie	**ADF** (p)	**KPSS** (p)
Tasa	0.184	0.010
∇ Tasa	0.357	0.100
IPI desest.	0.132	0.010
∇ IPI desest.	0.010	0.100

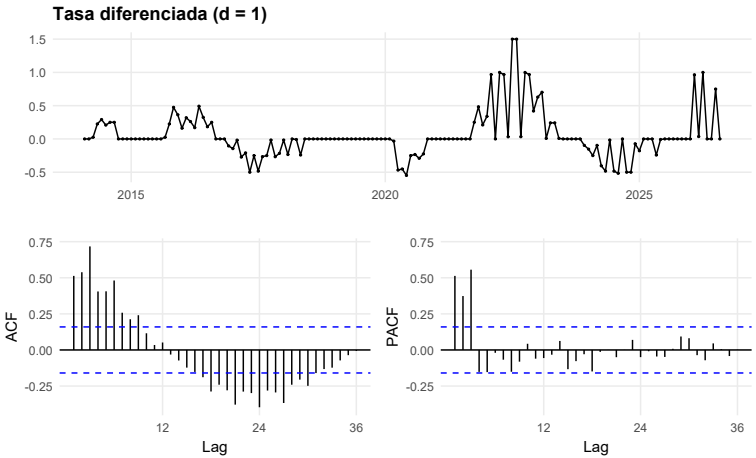
ADF: H_0 raíz unitaria. KPSS: H_0 estacionaria.

- En niveles ambas series tienen **raíz unitaria**.
- `ndiffs` (KPSS) sugiere $d = 1$ para las dos series.
- La tasa cambia en "escalones", y eso reduce la potencia del ADF.

Decisión

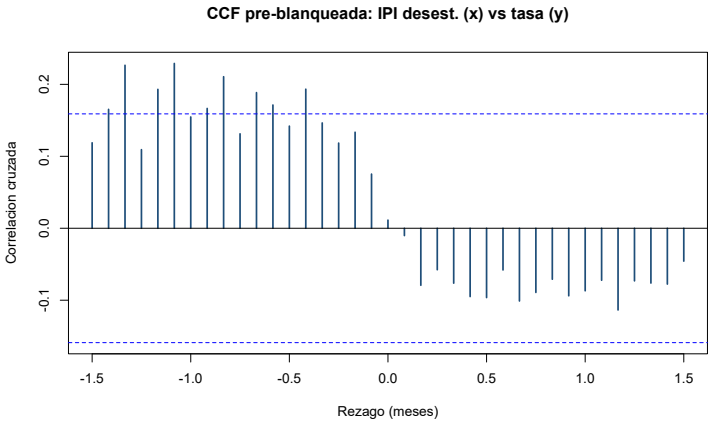
$d = 1$: se trabaja con $\nabla = (1 - B)$.

Tasa diferenciada: ACF y PACF



- ∇y_t oscila alrededor de cero.
- La ACF y la PACF muestran dependencia significativa.
- Se necesita un componente ARMA para los errores.

Pre-blanqueamiento y CCF



1. ARIMA al IPI: $\alpha_t = \frac{\phi_x(B)}{\theta_x(B)}\nabla x_t$.
2. Mismo filtro a la tasa: $\beta_t = \frac{\phi_x(B)}{\theta_x(B)}\nabla y_t$.
3. $\mathrm{CCF}(\alpha_t, \beta_{t+k})$ con bandas $\pm 1.96/\sqrt{T}$.

Barras **positivas** y significativas en rezagos **negativos** (entre -1.4 y -0.6): el IPI se **adelanta** a la tasa.

En R el eje de la CCF está en **años**: $-0.5 = 6$ meses, $-1 = 12$ meses.

Modelo estimado

Regresión con errores ARIMA(4,1,1)

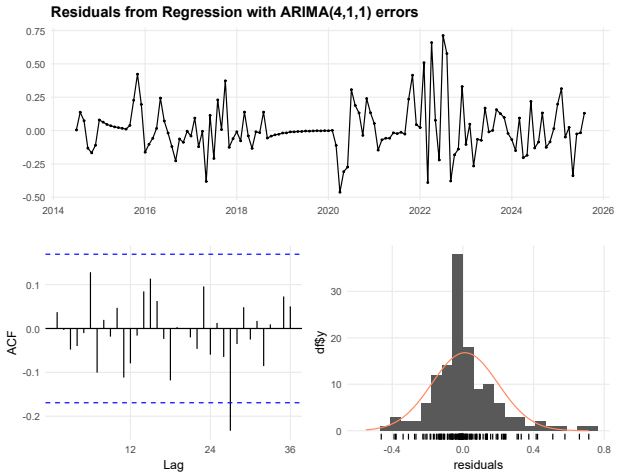
$$y_t = \beta_1 \, \mathrm{IPI}_t + \beta_2 \, D_t^{COVID} + n_t, \qquad \phi(B)\,(1-B)\,n_t = \theta(B)\,w_t$$

$$\phi(B) = 1 - \phi_1 B - \phi_2 B^2 - \phi_3 B^3 - \phi_4 B^4, \qquad \theta(B) = 1 - \theta_1 B$$

Modelo	**Especificación**	**AIC**	**BIC**
Modelo 0: ARIMA	ARIMA(4,1,1)	-52.78	-35.44
Modelo 1: IPI + COVID	ARIMA(4,1,1) errores	—	—
Modelo 2: IPI rezagos + COVID	—	—	—

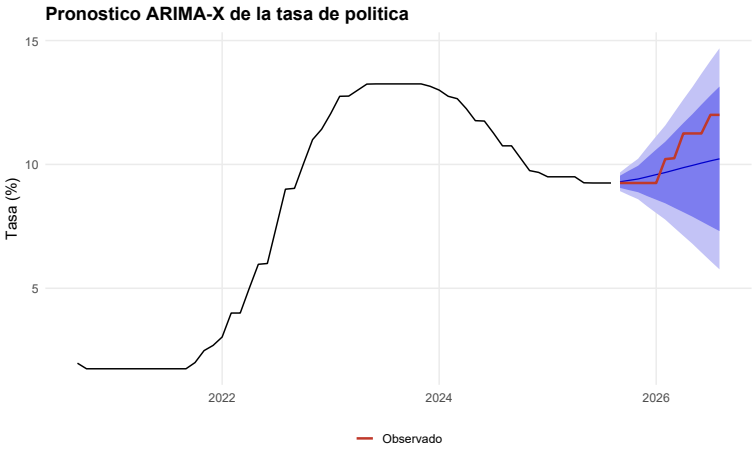
Completar con `resultados/ic_modelos.csv` y `coef_m1_arimax.csv`.

Diagnóstico de residuos



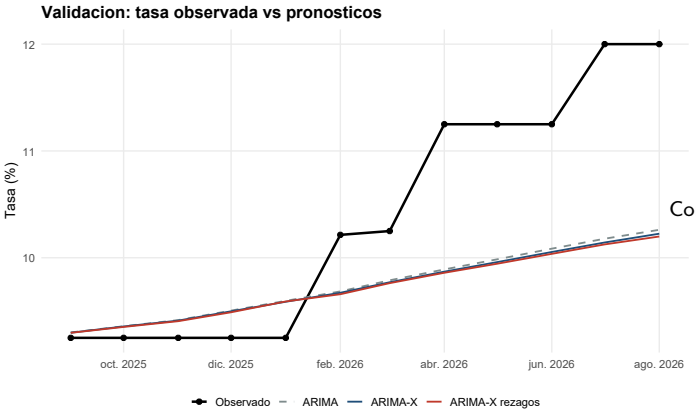
- Los residuos oscilan alrededor de cero; la dummy controla el choque de 2020.
- La ACF de los residuos queda dentro de las bandas (salvo un rezago aislado).
- Ljung-Box (24 rezagos): no se rechaza H_0, los residuos son **ruido blanco**.
- Histograma con colas pesadas: la normalidad es dudosa (Shapiro-Wilk).

Pronóstico ARIMA-X



- Intervalos de confianza del 80 % y 95 %.
- Con $d \geq 1$ la varianza del error de pronóstico crece con h, y las bandas se ensanchan.
- Pronóstico **ex post**: se usa el IPI observado del periodo de validación.

Validación fuera de muestra



Modelo	RMSE	MAE	MAPE
ARIMA	—	—	—
ARIMA-X	—	—	—
ARIMA-X rez.	—	—	—

Completar con `metricas_validacion.csv`

- Los tres pronósticos son **casi idénticos**.
- Ninguno anticipa el alza de la tasa de 2026 (de 9.25 % a 12 %): fue una decisión de política, no un efecto del IPI.

Conclusiones

1. **MCO no es válido con inercia temporal:** con series I(1), produce regresión espuria y errores estándar subestimados.
2. **ARIMA-X:** modela a la vez el efecto de la economía real y la memoria de la serie, con errores ARIMA(4,1,1).
3. **Causalidad rezagada:** el pre-blanqueamiento muestra que el IPI se adelanta a la tasa varios meses.
4. **Pronóstico:** en la validación, el IPI aporta poco frente al ARIMA univariado; la tasa responde sobre todo a la inflación y a decisiones de política.
5. **Intervención COVID-19:** la dummy estabiliza la varianza residual, y los residuos quedan como ruido blanco (Ljung-Box, $p > 0.05$).

Limitación: pronóstico ex ante

Las regresoras también deben pronosticarse

Para predecir y_{T+h} se necesitan los valores futuros del IPI. Su incertidumbre se transmite al pronóstico de la tasa:

$$\mathrm{Var}(e_y(h)) \;\approx\; \mathrm{Var}(e_n(h)) + \beta' \,\mathrm{Var}(e_x(h))\,\beta$$

- La ventaja del ARIMA-X está en el **corto y mediano plazo**.
- En la práctica se usan pronósticos del IPI o **escenarios**.

Referencias

- Amézquita Bravo, C. C. (2021). *Evaluación de modelos de series de tiempo para pronosticar la demanda de transporte aéreo a corto y mediano plazo en Colombia* [Tesis de maestría]. Universidad Nacional de Colombia.
- Box, G. E. P. y Tiao, G. C. (1975). Intervention analysis with applications to economic and environmental problems. *JASA*, 70(349), 70–79.
- Chen, C. y Liu, L.-M. (1993). Joint estimation of model parameters and outlier effects in time series. *JASA*, 88(421), 284–297.
- DataCamp. (2024). *Exogenous vs. Endogenous Variables: Key Differences and Examples*.
- Hyndman, R. J. y Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3.a ed.). OTexts.
- Ljung, G. M. y Box, G. E. P. (1978). On a measure of lack of fit in time series models. *Biometrika*, 65(2), 297–303.
- Ortiz Martín, R. (2022). *Metodología ARIMAX aplicada al análisis de la evolución de datos de suicidios en España* [TFG]. Universitat de Barcelona.
- Shumway, R. H. y Stoffer, D. S. (2017). *Time Series Analysis and Its Applications* (4.a ed.). Springer.
- Wei, W. W. S. (2006). *Time Series Analysis: Univariate and Multivariate Methods* (2.a ed.). Addison-Wesley.

¡Gracias!

Preguntas